

INFORME TÉCNICO

Script de Inserción de Datos — Módulo 4 **Módulo de Predicción**

Sergio Augusto Garcia Murcia

Sistema de Gestión Pecuaria

Fecha: 07/5/2026

1. Introducción

El presente informe documenta el script de inserción de datos semilla para el Módulo 4 del Sistema de Gestión Pecuaria, correspondiente al Motor de Predicción e Inferencia basado en Inteligencia Artificial bajo metodología CRISP-DM. Este módulo constituye la capa de análisis predictivo del sistema, convirtiendo los datos de telemetría IoT (M03) y las observaciones clínicas manuales en predicciones de riesgo patológico accionables para el productor y el veterinario.

Los datos semilla modelan el ciclo completo de vida del motor de predicción: desde la configuración del catálogo de signos clínicos y el versionado de modelos, pasando por el entrenamiento y detección de drift, hasta la ejecución de inferencias en tiempo real y la generación de alertas patológicas con su respectiva trazabilidad de auditoría.

2. Hallazgo Arquitectónico Crítico — FKs Eliminadas en Migración

Durante la verificación del DDL (backup4_0_0.sql), se identificó un patrón arquitectónico relevante que condiciona el diseño del script de inserción y del script de constraints: el módulo 4 tiene dos categorías de claves foráneas con comportamientos completamente distintos.

Categoría	Estado en el backup	Implicación para el seed
FKs internas (M4 → M4)	ADD CONSTRAINT ... NOT VALID (11 FKs)	Se activan con VALIDATE CONSTRAINT en constraints_modulo4.sql
FKs externas (M4 → M1/M2/M9)	DROP CONSTRAINT (11 FKs eliminadas en migración)	Son referencias lógicas sin constraint formal. El seed usa IDs válidos pero no hay verificación automática en BD.

Las FKs externas eliminadas incluyen referencias a modulo1.usuarios, modulo2.activos_biologicos, modulo9.patologias, modulo9.fincas y modulo1.notificaciones. Esta decisión arquitectónica fue tomada deliberadamente (probablemente para desacoplar módulos en despliegues distribuidos). El script de inserción respeta estas referencias lógicas usando IDs que deben existir en los módulos dependientes, verificados por el bloque DO \$\$ de precondiciones.

3. Dependencias y Orden de Ejecución

El Módulo 4 tiene dependencias con tres módulos externos. El orden de ejecución obligatorio es:

#	Script	Razón
1	script_insercion_m1_v2_0.sql	Crea modulo1.usuarios (id=1 Admin, id=2 Productor/Veterinario) y modulo1.notificaciones
2	script_insercion_m9_v2_0.sql	Crea modulo9.patologias (ids 1-3) y modulo9.fincas (id=1)
3	script_insercion_m2_v2.sql	Crea modulo2.activos_biologicos (ids 1-4 para BOV-001 a BOV-004)
4	constraints_modulo4.sql	Activa las 11 FKs NOT VALID internas y crea los nuevos constraints

#	Script	Razón
5	script_insercion_m4.sql (este)	Inserta los datos semilla del módulo 4 en el orden correcto

El script incluye un bloque DO \$\$ de precondition que verifica la existencia de usuarios (ids 1-2), patologías (ids 1-3) y activos biológicos (ids 1-3) antes de ejecutar cualquier INSERT. Si alguna verificación falla, el script se detiene con mensaje descriptivo que indica qué script ejecutar primero.

4. ENUMs del Módulo 4

El módulo 4 define 10 tipos ENUM en PostgreSQL. Antes de ejecutar el script, verificar que los literales usados coincidan exactamente con los valores definidos en el DDL:

Ref.	Tipo ENUM	Valores
E1	enum_alerta_patologia_estado	PENDIENTE, NOTIFICADA, ATENDIDA, FALSO_POSITIVO, CERRADA
E2	enum_auditoria_prediccion_accion	INSERT, UPDATE, ALERTA_ACTIVADA, VALIDACION_VET
E3	enum_ciclo_entrenamiento_estado_ciclo	PLANIFICADO, EN_PROCESO, COMPLETADO, FALLIDO, CANCELADO
E4	enum_ciclo_entrenamiento_tipo	SEMESTRAL, DRIFT_DETECTADO, MANUAL
E5	enum_datset_semestre	S1, S2
E6	enum_metrica_drift_tipo	PSI, KL_DIVERGENCE, ACCURACY_DRIFT, DISTRIBUCION_FEATURE
E7	enum_metrica_drift_accion_tomada	NINGUNA, ALERTA_GENERADA, REENTRENAMIENTO_INICIADO
E8	enum_predicciones_clase	POSITIVO, NEGATIVO, INDETERMINADO
E9	enum_signo_clinico_tipo	FISICO, COMPORTAMENTAL, METABOLICO, PODAL
E10	enum_version_modelo_algoritmo	RANDOM_FOREST, XGBOOST, RED_BAYESIANA, MLP

5. Orden de Inserción y Datos Semilla

Las 11 secciones respetan las dependencias de FKs internas, insertando siempre la tabla padre antes que las hijas:

#	Tabla	Datos insertados
1	signos_clinicos	11 signos del catálogo clínico: 4 físicos (temperatura, FR, FC, BCS), 2 comportamentales (inactividad, anorexia, aislamiento), 2 metabólicos (hipocalcemia, cetosis), 1 podal (cojera), 1 ambiental (temperatura IoT)
2	versiones_modelos	3 versiones: v1.0 Random Forest (retirada), v1.1 Random Forest (en producción, esta_produccion=true), v2.0 XGBoost

#	Tabla	Datos insertados
		(experimental, sin despliegue)
3	datasets	3 datasets (uno por versión): DS-2024S1 (1200 reg, 70/30), DS-2024S2 (2800 reg, 75/25), DS-2025S1-XGB (3500 reg, 75/25)
4	patologias_signos	13 asociaciones para 3 patologías de M9: estrés térmico (5 signos), cetosis subclínica (4 signos), hipocalcemia posparto (4 signos). Con peso_relativo y sensibilidad bibliográficos
5	ciclos_entrenamientos	3 ciclos CRISP-DM: S1/2024 (COMPLETADO, baseline), S2/2024 (COMPLETADO, drift=0.042, AUC mejoró +0.037), S1/2025 (EN_PROCESO, experimental XGBoost)
6	observaciones_clinicas	5 observaciones: BOV-001 (normal), BOV-003 (estrés térmico leve), BOV-004 (cetosis posparto), BOV-002 (normal IoT), BOV-003 (estrés crítico — escalación)
7	predicciones	5 predicciones coherentes: 2 NEGATIVO (prob 22.5% y 15.8%), 3 POSITIVO (prob 82.3%, 78.6% y 94.1%). Todas con supera_umbral coherente y latencia ≤ 2000 ms
8	alertas_patologicas	3 alertas: ALTA 82.3% (ATENDIDA, retroalimentación verdadero positivo), ALTA 78.6% (NOTIFICADA, pendiente vet), CRITICA 94.1% (PENDIENTE, escalación urgente)
9	auditorias_predicciones	8 registros append-only cubriendo el ciclo: INSERT → ALERTA_ACTIVADA → VALIDACION_VET para las predicciones positivas
10	metricas_drift	7 métricas para v1.0 y v1.1: PSI, KL_DIVERGENCE, ACCURACY_DRIFT y DISTRIBUCION_FEATURE. El PSI de temperatura en v1.0 (0.1875 > 0.15) originó el reentrenamiento semestral
11	detalles_signos	25 registros ligando cada observación con sus signos clínicos específicos, con valor_numerico, intensidad (1-5) y notas clínicas

6. Descripción Detallada por Sección

6.1 Signos Clínicos (RF-64)

Se insertan 11 signos que conforman el catálogo clínico del motor de predicción, mapeado al catálogo I3P-1 de variables del sistema IoT. Los signos físicos (temperatura, FR, FC, BCS) son medibles tanto por observación veterinaria manual como por sensores IoT del M03, lo que permite inferencia mixta (fuente_datos='mixta'). El signo 11 (temperatura ambiental) es exclusivamente de origen IoT.

Los signos metabólicos (hipocalcemia y cetosis) requieren laboratorio o dispositivos especializados (tiras de cetona, analizadores de BHBA), por lo que tienen requiere_laboratorio=true. El campo escala_medicion documenta la unidad y rango clínico de referencia para validación en la capa de aplicación.

Restricción RF-64: una patología solo es considerada inferible si tiene al menos 2 signos asociados. Los 13 registros de patologias_signos garantizan que las 3 patologías semilla tengan 4-5 signos cada una, superando el mínimo requerido.

6.2 Versiones del Modelo (RF-68, RF-69)

Se insertan 3 versiones que representan la evolución del modelo a lo largo de 2 ciclos CRISP-DM. La versión v1.1-RF-2024S2 tiene esta_produccion=true, cumpliendo la restricción de que solo puede haber una versión en producción simultáneamente (garantizada por el índice único parcial uix_una_version_en_produccion del script de constraints).

Todos los artefactos usan formato ONNX, el único formato permitido junto a TensorFlow SavedModel según la restricción 2 de RF-68 (el formato Pickle está explícitamente prohibido por riesgo de deserialización insegura). El campo hash_artefacto (tipo en el DDL) tiene exactamente 64 caracteres hex correspondientes a SHA-256, validado por chk_hash_artefacto_longitud.

La coherencia temporal es verificada por los constraints: fecha_despliegue >= fecha_entrenamiento, y la v1.0 tiene fecha_retiro posterior a fecha_despliegue. La versión experimental v2.0 no tiene fecha_despliegue (NULL), indicando que aún no ha sido desplegada.

6.3 Datasets (RF-70)

Los 3 datasets cumplen las restricciones críticas de RF-70: (1) porcentaje_train + porcentaje_test = 100 exactamente (check chk_split_ds ya en DDL), (2) fecha_fin_datos >= fecha_inicio_datos (check chk_fechas_ds ya en DDL), (3) total_registros >= registros_positivos + registros_negativos (check nuevo en constraints). Todos tienen tiene_variables_ambientales=true, indicando integración con telemetría IoT del M03. El campo descripcion incluye el hash SHA-256 simulado del dataset para trazabilidad, cumpliendo el requisito de RF-70 de versionado obligatorio del dataset.

6.4 Patologías-Signos (RF-64)

Las 13 asociaciones documentan las relaciones entre las 3 patologías del catálogo M9 y los signos clínicos del módulo 4. El campo peso_relativo indica la contribución del signo al diagnóstico de la patología (suma total ≈ 1.0 por patología), mientras que sensibilidad refleja la probabilidad de que el signo esté presente dado que la patología existe (validación clínica bibliográfica). El campo fuente_evidencia cita las referencias bibliográficas que respaldan los valores, cumpliendo la exigencia de evidencia científica de RF-64.

6.5 Ciclos de Entrenamiento (RF-70)

Los 3 ciclos representan la metodología CRISP-DM semestral: el primer ciclo (2024-S1) establece el modelo baseline sin versión anterior; el segundo ciclo (2024-S2) detectó drift en temperatura corporal ($PSI=0.042 > umbral=0.15$ relativo al ciclo anterior) y produjo una mejora de AUC-ROC de +0.037; el tercer ciclo (2025-S1) está en proceso con un modelo XGBoost experimental. El constraint chk_ciclo_modelos_distintos garantiza que el modelo anterior y nuevo sean diferentes, y uq_ciclo_semestre garantiza unicidad por semestre.

6.6 Observaciones Clínicas (RF-65)

Las 5 observaciones modelan un escenario de escalación clínica real: BOV-003 (Toro Simmental) es observado con estrés térmico leve (obs.2, temp 39.8 °C) y luego, 3 días después, es reevaluado con cuadro crítico (obs.5, temp 40.2 °C). Este patrón de escalación demuestra el historial diagnóstico de un mismo activo (RF-66). La fuente_datos='mixta' combina datos IoT con observación veterinaria directa. BOV-002 tiene fuente_datos='iot' indicando inferencia automatizada desde telemetría.

6.7 Predicciones (RF-65, RF-66)

Las 5 predicciones mantienen coherencia matemática estricta: $\text{supera_umbral} = (\text{probabilidad_pct} \geq \text{umbral_usado})$, garantizada por el constraint `chk_pred_supera_umbral_coherente`. El `umbral_usado=75.00` es el valor del modelo v1.1 en producción. Las 3 predicciones positivas (82.3%, 78.6% y 94.1%) superan el umbral y generan sus respectivas alertas. Las 2 negativas (22.5% y 15.8%) no generan alerta. Todas las latencias están dentro del SLA de 2000 ms definido en RF-65 (rango: 145-234 ms).

6.8 Alertas Patológicas (RF-67)

Las 3 alertas son generadas exclusivamente desde predicciones con `supera_umbral=true`, cumpliendo la restricción del motor de alertas. El nivel `criticidad` se mapea directamente a la probabilidad: CRITICA ($\geq 90\%$) para 94.1%, ALTA ($\geq 75\%$) para 82.3% y 78.6%. La Alerta 1 tiene retroalimentación veterinaria completa (`es_verdadero=true`, `diagnostico_confirmado`, `estado=ATENDIDA`), demostrando el ciclo de vida completo RF-71. La Alerta 3 (CRITICA, BOV-003) permanece PENDIENTE para representar una alerta activa sin resolver.

6.9 Auditorías de Predicciones (RF-72)

Los 8 registros de auditoría son append-only (inmutables por diseño del sistema). Cubren los 3 tipos de acción más relevantes: INSERT (registro inicial de cada predicción), ALERTA_ACTIVADA (evento del motor de alertas cuando `supera_umbral=true`), y VALIDACION_VET (retroalimentación clínica del veterinario). El campo `ip_origen` y `servicio_origen` permiten identificar el componente del sistema que generó cada evento, cumpliendo el esquema mínimo de RF-72.

6.10 Métricas de Drift (RF-70)

Las 7 métricas cubren los 4 tipos del enum para las versiones v1.0 y v1.1. El valor crítico es el PSI de temperatura corporal en v1.0 ($0.1875 > \text{umbral } 0.15$), que tiene `accion_tomada='REENTRENAMIENTO_INICIADO'` y es la causa documentada del ciclo de reentrenamiento S2/2024. Los demás valores están bajo umbral con `accion_tomada='NINGUNA'`. La última métrica de v1.1 (`DISTRIBUCION_FEATURE` de temperatura ambiental, valor $0.1638 > \text{umbral } 0.15$) tiene `accion_tomada='ALERTA_GENERADA'`, indicando que el modelo v1.1 empieza a mostrar señales tempranas de drift estacional.

6.11 Detalles de Signos (RF-65)

Los 25 registros documentan los signos específicos observados en cada visita clínica. La observación crítica (obs.5, BOV-003 estrés severo) tiene intensidad 4-5 en todos sus signos, coherente con un cuadro grave. El campo `es_presente=false` en los registros negativos (signo ausente) cumple el constraint `chk_detalle_intensidad_coherente` que garantiza que un signo ausente no tenga intensidad asignada. La restricción `uq_det_obs_signo` (única en constraints) garantiza que no se duplique el mismo signo en la misma observación.

7. Escenario Clínico Modelado — Escalación BOV-003

El conjunto de datos semilla modela deliberadamente un escenario de escalación clínica para ilustrar el ciclo completo del motor de predicción:

Momento	Observación	Predicción	Alerta	Estado
T-3 días	Obs.2 — Temp 39.8 °C, FR 42 rpm	Pred.2 — Estrés 82.3%	Alerta 1 — ALTA	ATENDIDA (vet confirmó)
T-12 horas	Obs.5 — Temp 40.2 °C, FR 48 rpm	Pred.5 — Estrés 94.1%	Alerta 3 — CRITICA	PENDIENTE (sin resolver)

Este escenario demuestra: (1) el historial diagnóstico del activo biológico (RF-66), (2) la escalación de severidad de una alerta activa (RF-67), (3) la retroalimentación veterinaria con validación clínica (RF-71), y (4) la trazabilidad completa de auditoría (RF-72) desde la observación hasta la alerta y la retroalimentación.